



Факультет географии и геоинформационных
технологий

Курсовая
работа

Москва
2025

Критический анализ базы данных "Опасные природные явления РФ по данным открытых источников"

Студент: Диденко Мария Олеговна

Научный руководитель: Зотова Мария Владимировна





Цель и исследовательский вопрос

- **Цель:** Провести критический анализ БД ОПЯ, выявить ее недостатки и предложить методы улучшения качества данных и их классификации с применением современных технологий машинного обучения и обработки естественного языка (NLP).
- **Исследовательский вопрос:** Как можно повысить качество, полноту и структурированность базы данных опасных природных явлений с помощью методов машинного обучения и обработки естественного языка (NLP) для более эффективного анализа и прогнозирования стихийных бедствий?
- **Данные:** База данных "Опасные природные явления РФ по данным открытых источников" 2018 – 2024 (30 тыс. строк). Данные предоставлены центром геоданных НИУ ВШЭ.





Задачи

1. Провести обзор существующих мировых баз данных по опасным природным явлениям, их характеристик, критериев включения событий и спецификации.
2. Проанализировать структуру и содержание российской базы данных ОПЯ.
3. Исследовать связи между количеством новостей об ОПЯ, источниками данных и демографическими характеристиками регионов.
4. Исследовать современные подходы к фильтрации и классификации сообщений о природных катастрофах.
5. Провести детальный анализ опасного природного явления "сильные ветры" и разработать методику определения интенсивности этого явления на основе текстовых описаний.
6. Применить методы тематического моделирования для выявления ключевых тем в описаниях ОПЯ, ущербов и адаптационных мер.
7. Разработать и оценить модели машинного обучения и NLP для автоматической классификации сообщений по интенсивности ОПЯ.
8. Предложить подходы к улучшению структуры и содержания базы данных ОПЯ.






Существующие базы данных

БД	Создатель, охват	Фокус, особенности и их недостатки
EM-DAT (Emergency Events Database), 1900 г.	CRED (Центр исследования эпидемиологии катастроф), мировой	Широкий охват фиксирует крупные катастрофические события, связанные с природными, технологическими и комплексными явлениями. Открытый доступ, активно используется в научных исследованиях и гуманитарных программах. Высокая доля пропусков, особенно по экономическим убыткам.
NatCatSERVICE (Munich Re), 1974 г.	Страховая компания Munich Re, мировой	Подробная информация о природных катастрофах, особенно для нужд страхования и перестрахования. Не является открытой. Требуется значительных усилий от пользователей по валидации и стандартизации данных.
Sigma (Swiss Re), 1970 г.	Страховая компания Swiss Re, мировой	Экономические потери от катастроф (природные, так и технологические бедствия). Не является полностью открытой, применяется в страховой и финансовой аналитике.
GLIDE (Global Identifier Number)	Японское агентство по международному сотрудничеству ADRC, мировой	Присваивает уникальные идентификаторы катастрофам для унификации данных между различными базами. Не самостоятельная база, а система идентификации событий.
GFDRR (Global Facility for Disaster Reduction and Recovery), 2006 г.	World Bank, мировой	Оказывает помощь странам с низким и средним уровнем дохода, помогая им оценивать и уменьшать свою уязвимость перед стихийными бедствиями и изменением климата. Используется для формирования политики и программ по снижению риска бедствий.
BD CATNAT Global , 2001 г.	Колсалтинговая компания Ubyrisk Consultant, мировой	Включает опасные природные явления с любым человеческим и экономическим ущербом (низкий порог входа). База на французском языке
DesInventar , 1997 г.	LA RED, региональный	Мелкомасштабные и крупные катастрофы, особенно в странах Латинской Америки и Карибского бассейна. Включает данные о частых, но менее масштабных событиях, которые часто не попадают в глобальные базы.

Создание БД ОПЯ

Рассмотренные этапы



- Пользовательская БД содержит только реализованные события (10 753 новостей)
- В работе рассматриваются записи категории реализованные события и другие записи, где заполнено поле "Мероприятия"






Коды и материалы проекта

GitHub

- Профиль: uroplatus666
- Репозиторий: adaptation



Основные используемые в работе библиотеки python™


- Pandas
- GeoPandas
- NumPy
- Matplotlib
- Seaborn
- Plotly
- WordCloud
- re
- String
- NLTK
- Natasha
- Collections
- scikit-learn
- Transformers
- Sentence-Transformers
- SciPy
- PyTorch

• adaptation // GitHub [Электронный ресурс]. Режим
доступа: <https://github.com/uroplatus666/adaptation>



Проблемы БД ОПЯ

- Несоответствие форматов даты начала и конца событий: словесные описания, путаница в дате и месяце, несоответствие года и даты.
- Неунифицированные разделители в полях с типом ОПЯ и локацией, затрудняющие обработку.
- Текстовые описания явлений, ущерба и мер представлены в разных форматах (предложения, списки, словари), с повторениями и отсутствием систематизации.




- Отсутствие экономической оценки ущерба в 99.3% случаев, и ущерба жизни и здоровью людей (погибшие и пострадавшие) – в 98.1% и 95.3 % соответственно.
- Верификация событий отсутствует в 96.4% новостей.
- В 2018 – 2020 гг. собрано сильно меньше данных чем в 2021 – 2024 гг.





Зависимость между количеством новостей об ОПЯ, источниками данных и демографическими характеристиками регионов

1. Новости об ОПЯ составляют малую долю (4,43%) от общего потока новостей в выбранных сообществах.
2. Корреляция между числом источников (используемых и рассматриваемых) и количеством новостей статистически значима.
3. Корреляции между количеством новостей, числом источников (используемых и рассматриваемых) и численностью населения регионов статистически значимы.





Количество рассматриваемых новостей, источников и население субъектов РФ



Фильтрация новостей

Существует три самостоятельных подхода для определения опасных природных явлений по новостям:

- работать только с текстовой частью новости;
- рассматривать только фотографии, прикрепленные к новости;
- мультимодальный подход

Disaster-Twitter-XLM-RoBERTa-AL


Было рассмотрено 20000 новостей «РИА Новости» (95.57 %), не относящихся к ОПЯ, и 927 (4.43 %) новости из БД ОПЯ, полученные из ВК

- Precision = 0.89
- Recall = 0.88

Для создания БД ОПЯ собрано: 8.3 млн новостей, из них отфильтровано как ОПЯ - 52440. Выборка для оценки качества: 300 новостей МЧС

- Precision = 0.93,
- Recall = 0.04

Внутренний отчет Центра геоданных ВШЭ, 2024



Koshy R., Elango S. Multimodal tweet classification in disaster response systems using transformer-based bidirectional attention model // Neural Computing and Applications. — 2023. — Vol. 35. — No. 2. — P. 1607–1627.



Анализ выбранного ОПЯ. Сильные ветры

- Применение регулярных выражений к тексту новостей позволило определить классы интенсивности по шкале Бофорта для 66.45% новостей о сильных ветрах.
- Информация об интенсивности в столбце с описанием ОПЯ даёт меньше результатов, чем работа с исходным текстом.
- В полях с описаниями ущерба и мер адаптации отсутствует структура и классификация.
- Применен метод тематического моделирования LDA для извлечения ключевых тем по классам интенсивности ОПЯ и регионам.

	GPT-модель	
	Сильные ветры	Сильные ветры и/или КНПЯ
Precision	0.96	0.98
Recall	0.23	0.74

- Результаты LDA можно использовать для разработки классификации ущербов и мер адаптации, далее проводить разметку и делать fine-tuning предобченной модели (например, BERT).



Классификация новостей по интенсивности ОПЯ (сильного ветра)

Классы

Класс по Бофорту	Количество новостей	Группы классов по Бофорту	Количество новостей
5	152	5-7	1369
6	181		
7	1036		
8	2582	8	2582
9	1826	9	1826
10	1913	10	1913
11	447	11-12	728


Random Forest

5 классов	Precision	Recall	F1-score
Accuracy	0.88		
Macro avg	0.88	0.86	0.87
Weighted avg	0.88	0.88	0.87
8 классов	Precision	Recall	F1-score
Accuracy	0.88		
Macro avg	0.88	0.71	0.87
Weighted avg	0.85	0.85	0.87


Fine-tuning BertForSequenceClassification, bert- base-uncased

Метрики	5 классов	8 классов
Accuracy	0.956	0.954
Precision (macro)	0.953	0.951
Recall (macro)	0.951	0.922
F1-score (macro)	0.956	0.934

- 2681 геокодированных новостей, обучающая выборка



- 4526 геокодированных новостей, обучающая выборка и предсказанные данные





Выводы

1. Критический анализ российской базы данных ОПЯ выявил существенные недостатки:
 - Значительные пропуски в данных об экономическом и человеческом ущербе.
 - Неструктурированность и неунифицированность текстовых описаний ОПЯ, ущерба и мер адаптации.
 - Отсутствие классификации ОПЯ по интенсивности.
2. Анализ подкатегории "сильные ветры" выявил, что их реальное количество в 4 раза превышает число событий, промаркированных в исходной базе, что было установлено с помощью разработанного регулярного выражения.
3. Применение методов тематического моделирования (LDA) для анализа текстовых описаний ОПЯ, ущербов и адаптационных мер позволило выявить ключевые темы, однако эффективное использование результатов затруднено отсутствием структурированной классификации.
4. Разработанная методика определения интенсивности ветра по шкале Бофорта на основе текстовых описаний позволила классифицировать 69% сообщений о сильных ветрах.
5. Разработанные модели машинного обучения и NLP продемонстрировали высокую эффективность при классификации сообщений о ветрах по интенсивности:
 - Random Forest: точность около 88%
 - Fine-tuned BERT: точность 95%



Дальнейшая работа над проектом

Ограничениями данного исследования являются фокус на одном типе ОПЯ (сильные ветры) и отсутствие реализации предложенного мультимодального подхода. В качестве направлений дальнейших исследований можно выделить:



- Разработку и внедрение мультимодальной архитектуры для классификации сообщений об ОПЯ, учитывающей как текстовую информацию, так и сопровождающие изображения.
- Создание и внедрение унифицированных классификаций для описания ущерба от ОПЯ и адаптационных мер.
- Расширение анализа на другие типы ОПЯ, представленные в базе данных.
- Поиск источников для регионов с маленьким количеством новостей





Спасибо за внимание!



Рассматриваемые виды опасных природных явлений

	Краткое название вида ОПЯ	Комментарии
Геофизические	Карст	
	Суффозия	
	Просадочность лессовых пород	
	Оползни, осыпи, обвалы	На естественных и антропогенных склонах
	Сели	
	Лавины	
	Эрозия	Эрозия плоскостная и овражная, термоэрозия
Гидрологические	Русловые деформации	Вертикальные и горизонтальные русловые деформации и береговая эрозия на водотоках
	Переработка берегов	Переработка берегов водохранилищ и озер
	Абразия	Абразия и термоабразия на морских берегах
	Наводнение	Наводнения гидрологической и плювиальной природы, подтопление, переувлажнение почвы, высокие уровни вод
Мерзлотные	Термокарст	Термокарст, деградация мерзлоты любой природы
	Пучение	
	Солифлюкция	
	Наледеобразование	Гидрологическое и гидрогеологическое наледеобразование



Рассматриваемые виды опасных природных явлений

	Краткое название вида ОПЯ	Комментарии
Метеорологические	Сильный ветер	Все виды сильных ветров — ураганы, смерчи, шквалы, сильный ветер (в т.ч. метель) и др.
	Пыльная буря	Пыльные, песчаные бури
	Засуха	Засуха, суховей
	Жара	Жара и аномально жаркая погода
	Заморозки	Заморозки на воздухе в вегетационный период
	Резкие перепады температуры	
	Мороз	Сильный мороз и аномально холодная погода
	Град	
	Сильные осадки	Сильный дождь, сильный снег
	Грозы	
	Туман	Сильный туман, мгла
	Гололед	Гололедно-изморозевые явления различной локализации и природы, в т.ч. ледяной дождь, ледяные корки, наледь на объектах
	КНПЯ	Комплекс неблагоприятных погодных явлений (КНПЯ)
Биосферные	Пожары	Ландшафтные пожары — лесные, степные, тундровые, луговые, и др.
	Вредители и болезни	Вредители и болезни лесов и с/х культур



Содержание БД ОПЯ

Имя поля	Содержание	Заполнение
_ID	Уникальный идентификатор для каждой обработанной новости	Заполняется автоматизированно генератором случайных ID
Event_ID	Идентификатор, объединяющий группу новостей про одно ОПЯ; создается для каждого из ОПЯ, перечисленных для записи в поле Phenomena	Создается только для строк, имеющих распознанный вид ОПЯ, геокодированные элементы и дату начала события в машиночитаемом формате
News_link	Ссылка на исходную публикацию	Сохраняется при парсинге новостей
Text	Полный текст статьи	
News_source	Тип источника новости	Заполняется автоматизированно на основе поля NewsLink
News_type	Тип новостного контента	Заполняется БЯМ
Location_ATD4	Список с именами всех регионов, в которых находятся локации, указанные в новости как затронутые ОПЯ	Заполняется на основании геокодирования локаций, распознанных БЯМ, имена нормализуются при геокодировании
Location_other	Список с именами всех локаций (без указания региона), которые распознались в тексте новости	
Location_geocoded	Отметка о выполнении геокодирования локаций из поля Location_other	"да" - если есть геокодированные элементы (=в шейп-файле существуют дочерние элементы), "нет" - ни одна из локаций не геокодирована
Date_year	Год возникновения события	Заполняется БЯМ, автоматизированно нормализуется при постобработке, ненормализованные записи исправляются вручную
Date_start	Дата начала события	
Date_end	Дата конца события	




Содержание БД ОПЯ

Имя поля	Содержание	Заполнение
Phenomena	Вид опасного природного явления, или нескольких, о которых идет речь в тексте	Заполняется БЯМ на основании фиксированного списка ОПЯ, написание нормализуется при постобработке
Event_verbose	Описательные сведения о протекании природного явления - интенсивности, площади, причинах возникновения и т.п.	Заполняется БЯМ
Damage_description	Описательные сведения о нанесенном ущербе - разрушениях, повреждениях, остановках транспортного сообщения и т.п.	
Damage_money_num	Монетарные оценки ущерба от явления, в руб.	Заполняется БЯМ, автоматизированно нормализуется при постобработке, ненормализованные записи исправляются вручную
People_dead_num	Количество погибших людей	
People_injured	Количество пострадавших и затронутых людей - эвакуированных, получивших вред здоровью, оказавшихся в зоне нарушения условий жизни и т.п.	Заполняется БЯМ
People_injured_num	Суммарное количество пострадавших людей в числовом формате	Поле People_injured автоматизированно нормализуется при постобработке, ненормализованные записи исправляются вручную
Activities	Меры и мероприятия, предпринимавшиеся до, во время и после события, направленные на его предотвращение, минимизацию ущерба, ликвидацию последствий и т.п.	Заполняется БЯМ
Verification_source	Название внешней базы данных, в которой найдены сведения о явлении (проверка на основе совпадения типа явления, дат и географии)	Заполняется по результатам полуавтоматизированной кросс-проверки
Verification_details	Дополнительные сведения о записи из внешней базы данных	

Временные рамки

Число сообщений в разные года. БД ОПЯ



Самый релевантный для оценки каких-либо параметров промежуток: 2021 - 2024 гг.

- 73.67% датасета
- Сообщения в 2024 году составляют 76.94% от максимума (2023 г)
- Сообщения в 2022 году составляют 80.76% от максимума (2023 г)
- Сообщения в 2021 году составляют 73.80% от максимума (2023 г)
- Сообщения в 2020 году составляют 37.97% от максимума (2023 г), далее этот процент еще сильнее снижается, что вряд-ли говорит о том, что в этом году до 2020 г, включительно, было настолько меньше ОПЯ, просто собрали сильно меньше данных





Интернет-источники для сбора текстовых сообщений

Search



Основной источник новостей — официальные группы ВК администраций муниципалитетов и регионов.

